

La clasificación de 2019 puesta a prueba, y las ocho parejas

Alberto Acedo Biome Makers Inc. Borrador v0.2, 8 de septiembre de 2026. Sustituye a la v0.1, que usaba la clasificación de 2010.

Nota previa

La versión anterior de esta nota contrastaba la clasificación de Montecchi (2010, Kadmos 49). La propia autora ha señalado que esa clasificación fue revisada y sustituida en su libro de 2019, *Contare a Haghia Triada*, páginas 97-107, y ha facilitado el volumen. Esta versión usa la clasificación revisada y añade la prueba que la nueva versión hace posible.

1. Las dos clasificaciones, medidas con la misma vara

clasificación	tablillas	pares misma serie	pares distinta serie	diferencia	nulo	p
2010, logogramas	88	0,210	0,036	0,174	0,000	< 0,0005
2019, logogramas	131	0,133	0,026	0,107	0,000	< 0,0005
2010, vocabulario	88	0,044	0,012	0,031	0,000	< 0,0005
2019, vocabulario	131	0,034	0,010	0,024	0,000	< 0,0005

Las dos se sostienen con la misma contundencia. La de 2019 muestra una cohesión interna algo menor (0,133 frente a 0,210 en logogramas), y la razón es aritmética y no metodológica: clasifica 131 tablillas en 39 clases y series, frente a las 88 en 23 de 2010. Al repartir más documentos en más grupos, los grupos son más finos y más numerosos, de modo que el promedio de similitud dentro de grupo baja necesariamente. La proporción entre lo de dentro y lo de fuera se mantiene: 5,1 veces en 2019, 5,8 en 2010.

Es decir: **la revisión de 2019 amplía la cobertura del corpus en un 49% sin perder discriminación**, que es exactamente lo que se pide a una clasificación revisada.

2. La prueba que la clasificación de 2019 hace posible: las ocho parejas

La novedad más contrastable del libro es que la autora marca **ocho parejas de tablillas homogéneas** por argumento, estructura del texto, lugar de hallazgo y, en la mayoría de los casos,

mano del escriba. Esa es una afirmación mucho más fina que la de agrupar en series, y se puede medir directamente.

marca	tablillas	Jaccard de logogramas	Jaccard de vocabulario
[1]	HT 85 / HT 122	0,429	0,107
[2]	HT 93 / HT 102	0,125	0,118
[3]	HT 86 / HT 95	0,000	0,545
[4]	HT 17 / HT 19	1,000	0,333
[5]	HT 16 / HT 20	0,400	0,000
[6]	HT 32 / HT 33	0,067	0,500
[7]	HT 114 / HT 121	0,833	0,667
[8]	HT 87 / HT 117	0,000	0,071

Media de las ocho parejas: 0,357 en logogramas y 0,293 en vocabulario. Media de los pares de la misma serie: 0,133 y 0,034. Media de todos los pares del corpus: 0,030 y 0,011.

Las ocho parejas son casi tres veces más cohesionadas que dos tablillas cualesquiera de la misma serie, y doce veces más que dos tablillas cualesquiera del corpus. Frente a un nulo que extrae ocho pares al azar de entre los de la misma serie, $p = 0,0038$; frente a ocho pares al azar del corpus, $p < 0,0002$.

Ese es el resultado más fuerte de esta nota, y merece subrayarse por lo que significa: **la autora identificó a mano, sin ninguna medida de similitud, las ocho parejas más cohesionadas de un corpus de ciento treinta tablillas.** No las series, que son un juicio de contenido; las parejas concretas, que es un juicio de detalle.

3. Los tres casos que explican por qué las dos medidas son necesarias

Tres parejas tienen cohesión alta en una medida y nula en la otra, y cada una ilustra un tipo distinto de parentesco:

HT 86 / HT 95 (marca [3], serie Ed): logogramas 0,000, vocabulario 0,545, la cifra más alta del corpus. No comparten ninguna mercancía y comparten más de la mitad de las palabras: registran KU-NI-SU, SA-RU, DI-DE-RU, DA-ME, MI-NU-TE y QE-RA₂-U con cantidades de 10 y 20. Son dos versiones del mismo documento, y la medida de logogramas no las vería.

HT 17 / HT 19 (marca [4], serie Ga): logogramas 1,000, vocabulario 0,333. Comparten la totalidad de sus mercancías. Es el parentesco de tipo, no de contenido.

HT 114 / HT 121 (marca [7], serie Ud): 0,833 y 0,667, alto en las dos. Es el parentesco completo, y son además de la misma mano (la 4, según la tabla de la autora) y del mismo vano.

HT 87 / HT 117 (marca [8], serie Va) da 0,000 y 0,071, y es la única de las ocho que las dos medidas no ven. La razón está en la propia clasificación: la clase V es la de las tablillas **sin ideograma**, de modo que no hay logogramas que comparar, y su parentesco es de estructura del texto, que ninguna de nuestras dos medidas capta. Es una limitación del instrumento y no de la clasificación, y la misma que ya observamos en la versión de 2010.

4. Serie, mano y vano: los tres factores separados

La tabla de 2019 incluye el **vano de hallazgo**, que la versión de 2010 no daba. Con él se pueden separar por primera vez tres factores hasta ahora confundidos: de qué trata el documento (la serie), quién lo escribió (la mano) y dónde se guardó (el vano).

De las 135 tablillas clasificadas, todas tienen vano, 59 tienen mano y 92 tienen además vocabulario suficiente para medir. Los vanos son ocho: Villa 59 (50 tablillas), Casa del Lebete 7 (34), Casa del Lebete 9 (20), Villa 72 (10), y cuatro menores.

Los tres a la vez (46 tablillas con los tres datos)

serie	mano	vano	pares	vocabulario compartido
igual	igual	igual	5	0,207
igual	distinta	distinto	11	0,094
igual	igual	distinto	4	0,045
distinta	igual	igual	28	0,028
igual	distinta	igual	12	0,021
distinta	distinta	distinto	688	0,018
distinta	distinta	igual	262	0,017
distinta	igual	distinto	25	0,016

La celda que coincide en las tres cosas domina a todas las demás, con más del doble que la siguiente y once veces la media del corpus. Con cinco pares es un indicio y no una medida.

Los dos con muestra suficiente (92 tablillas)

serie	vano	pares	vocabulario compartido
igual	igual	53	0,0805
igual	distinto	66	0,0432
distinta	igual	974	0,0196
distinta	distinto	3.093	0,0148

Con permutación dentro de estratos: **el efecto de la serie dentro del mismo vano es 0,0608 (nulo -0,002; $p < 0,002$); el efecto del vano dentro de la misma serie es 0,0373 (nulo 0,024; $p = 0,212$, no significativo).**

La lectura

La serie explica el vocabulario compartido; el vano no. Dos tablillas de la misma serie se parecen aunque se guardaran en habitaciones distintas (0,043, tres veces la media del corpus); dos tablillas del mismo vano no se parecen si no son de la misma serie (0,020, apenas por encima de la media).

Es lo que se esperaría de un archivo organizado por asunto y por responsable, y no de un depósito ordenado por conveniencia de almacenamiento. Y tiene una consecuencia para el uso arqueológico del dato: **el lugar de hallazgo no basta por sí solo para inferir parentesco documental**, aunque sea el criterio más accesible.

La jerarquía completa de factores

factor	efecto	significación
serie y mano coincidentes	0,216	la celda dominante
serie, mano y vano coincidentes	0,207	indicio, 5 pares
mano dentro de la misma serie	0,164	$p < 0,003$
serie dentro del mismo vano	0,061	$p < 0,002$
vano dentro de la misma serie	0,037	no significativo

El vocabulario de una tablilla lo determina el escriba trabajando dentro de un expediente concreto; dónde acabó guardada no añade nada.

Cautela sobre los vanos

En la tabla de 2019 muchas atribuciones de vano llevan interrogante, porque proceden de la reconstrucción de excavaciones de principios del siglo XX. Aquí se han tratado como firmes, porque excluirlas dejaría la muestra sin tamaño. La incertidumbre juega en dirección conservadora: si los vanos estuvieran mejor determinados, el efecto podría aparecer, no desaparecer. La afirmación que se sostiene es, por tanto, que **con los datos de procedencia disponibles el vano no explica el vocabulario compartido**, y no que no lo explicaría con datos mejores.

5. Reproducibilidad

Todas las cifras de esta nota se obtienen con dos funciones del paquete kuro, `group_cohesion` (cohesión de una agrupación frente a permutación de etiquetas) y `factor_effects` (similitud media por combinación de factores coincidentes), y se han verificado recalculándolas con código independiente y semilla distinta: las ocho parejas dan 0,3567 y 0,2927, los pares de la misma serie 0,1333, y las cuatro celdas de serie por vano coinciden a la cuarta cifra decimal. La clasificación de 2019 transcrita de la tabla 4 acompaña al trabajo como fichero de datos.

Datos

Clasificación: Montecchi (2019), *Contare a Haghia Triada. Le tavolette in lineare A, i documenti sigillati e il sistema economico-amministrativo nel TM IB*, Incunabula Graeca CVII, tabla 4, pp. 97-104. Corpus: GORILA vía LinearA Explorer (Hogan 2022), con las manos de GORILA V. Scripts: paquete kuro.

Declaración de asistencia

El procesamiento del corpus, las pruebas de permutación y el borrador de este texto se produjeron con la asistencia de un modelo de lenguaje (Claude, Anthropic) bajo la dirección del autor, responsable de todas las afirmaciones.

Referencias

Corazza, M., F. Tamburini, M. Valério y S. Ferrara 2022. Unsupervised deep learning supports reclassification of Bronze Age Cypriot writing system. PLOS ONE 17(7), e0269544. Godart, L. y J.-P. Olivier 1976-1985. Recueil des inscriptions en linéaire A, I-V. Paris. Hogan, R. 2022. Linear A Explorer. <https://lineara.xyz> Montecchi, B. 2010. A classification proposal of Linear A tablets from Haghia Triada in classes and series. Kadmos 49, 11-38. Montecchi, B. 2019. Contare a Haghia Triada. Incunabula Graeca CVII. Roma.